UNIVERSITAT DE BARCELONA

Comentarios a las distancias

(la pizarra)

Prof. Miquel Salicrú

Prof. Ferran Reverter

Diagrama de flujo

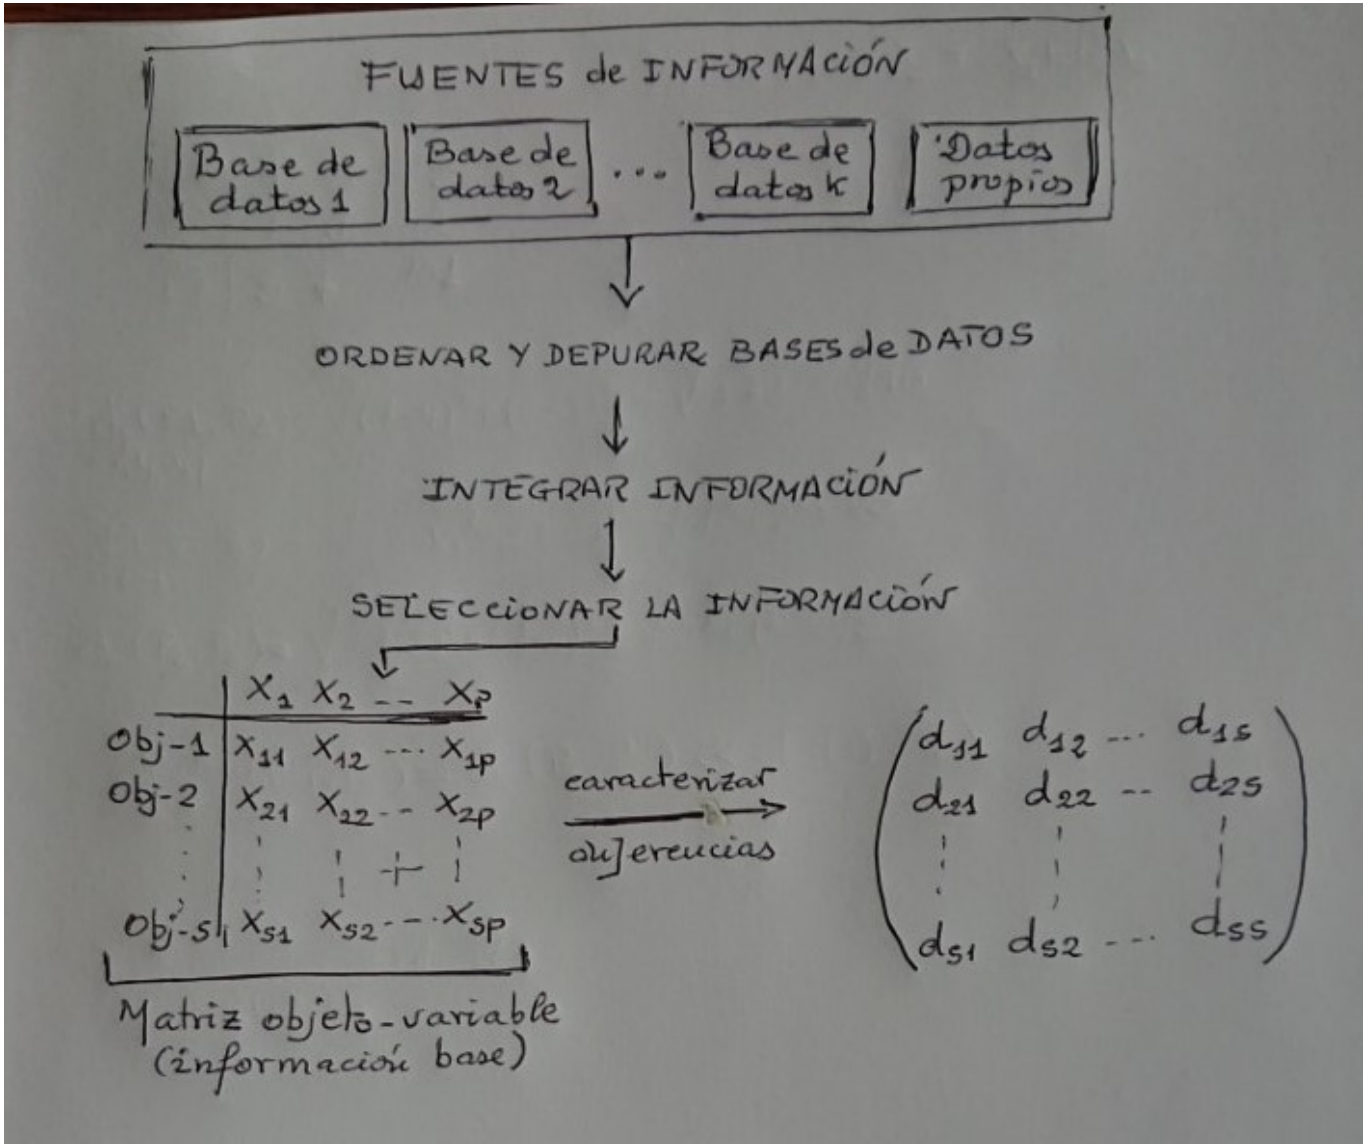

Distancia euclídea 1/3

Ejemplo 1

	X_1	X_2	$X_3 = 2X_1 + 13X_2$
Población 1	4	5	73
Población 2	7	6	92
Población 3	5	7	101

$\{X_1, X_2\}$

$\{X_1, X_2, X_3\}$

misma información

a) Distancia euclidea con $\{X_1, X_2\}$

$d(P1, P2) = \sqrt{(7-4)^2 + (6-5)^2} = \sqrt{10}$

$d(P1, P3) = \sqrt{(5-4)^2 + (7-5)^2} = \sqrt{5}$

$d(P_2, P_3) = \sqrt{(5-7)^2 + (7-6)^2} = \sqrt{5}$

Relación de orden

$d(P_1, P_3) = d(P_2, P_3) < d(P_1, P_2)$

b) Distancia euclídea con $\{X_1, X_2, X_3\}$

$d(P_1, P_2) = \sqrt{(7-4)^2 + (6-5)^2 + (92-73)^2} = 19{,}26$

$d(P_1, P_3) = \ldots\ldots\ldots\ldots = 28{,}09$

$d(P_2, P_3) = \ldots\ldots\ldots\ldots = 9{,}27$

$d(P_2, P_3) < d(P_1, P_2) < d(P_1, P_3)$

Sin cambiar la información cambian las relaciones de proximidad !!

Distancia euclídea 2/3

Ejemplo 2

	X_1	X_2
Población 1	4	0,5
Población 2	7	0.6

$\longrightarrow$ cambio escala

	$0.1 \cdot X_1$	$20 \cdot X_2$
Población 1	0.4	10
Población 2	0.7	12

$$d(P_1, P_2) = \sqrt{(7-4)^2 + (0.6-0.5)^2}$$

$$= \sqrt{3^2 + 0.1^2} = \sqrt{9 + 0.01}$$

$\uparrow$

las diferencias las marca X_1

$$d(P_1, P_2) = \sqrt{(0.7-0.3)^2 + (12-10)^2}$$

$$= \sqrt{0.4^2 + 2^2} = \sqrt{0.16 + 4}$$

$\uparrow$

las diferencias las marca X_2

Distancia euclídea 3/3

Información repetida en las bases de datos: ¿porqué?

- **Fuentes de información: para dar respuesta a objetivos genéricos (poco definidos o múltiples), resulta razonable recopilar la mayor cantidad posible de información.**
- **Hemos filtrado/escogido las variables de interés y el peso que queremos darles?**
- **Con información pseudo-incontrolada utilizar la distancia euclídea puede resultar muy arriesgado**
- **Con conocimiento experto y selección de variables, la distancia euclídea puede ser muy adecuada**

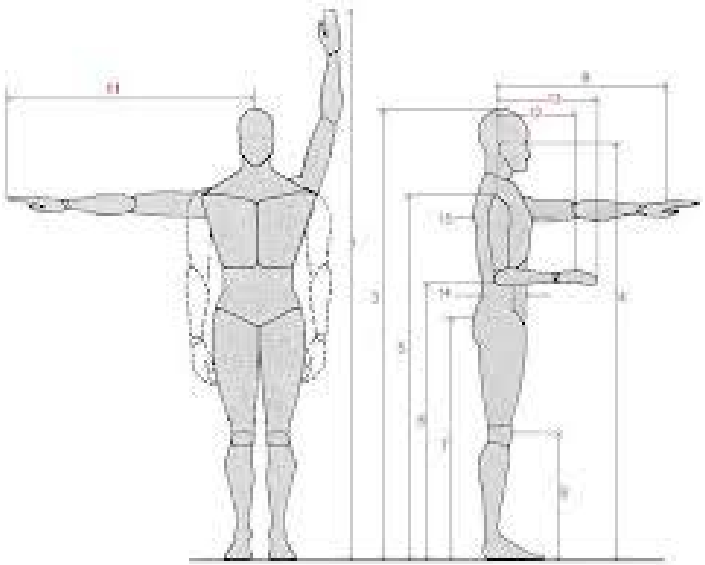

https://www.escuelaing.edu.co/uploads/laboratorios/2956_antropometria.pdf

Generalización con ponderaciones L^p

Generalización por criterios matemáticos con algún interés práctico

- **p>1**: potencia los valores altos (diferencias altas) y minimiza el efecto de las diferencias bajas.
- **p<1**: potencia los valores bajos (diferencias bajas) y reduce el efecto de las diferencias altas

	$\lvert x_{i1}-x_{j1}\rvert=0.1$	$\lvert x_{i2}-x_{j2}\rvert=1$	$\lvert x_{i3}-x_{j3}\rvert=10$	$\lvert x_{i4}-x_{j4}\rvert=50$	$\lvert x_{i5}-x_{j5}\rvert=100$	suma	raiz-p	Potencia
$\lvert x_{ik}-x_{jk}\rvert^2=$	0,010	1	100	2.500	10.000	12.601,010	112,254	Valores altos
$\lvert x_{ik}-x_{jk}\rvert^3=$	0,001	1	1.000	125.000	1.000.000	1.126.001,001	104,035	Valores altos
$\lvert x_{ik}-x_{jk}\rvert^5=$	0,000	1	100.000	312.500.000	10.000.000.000	10.312.600.001,000	100,618	Valores altos
$\lvert x_{ik}-x_{jk}\rvert^{0.5}=$	0,316	1	3,162	7,071	10	21,550	464,384	Valores pequeños
$\lvert x_{ik}-x_{jk}\rvert^{0.25}=$	0,562	1	1,778	2,659	3,162	9,162	7.046,443	Valores pequeños

Distancia por caminos o tiempos

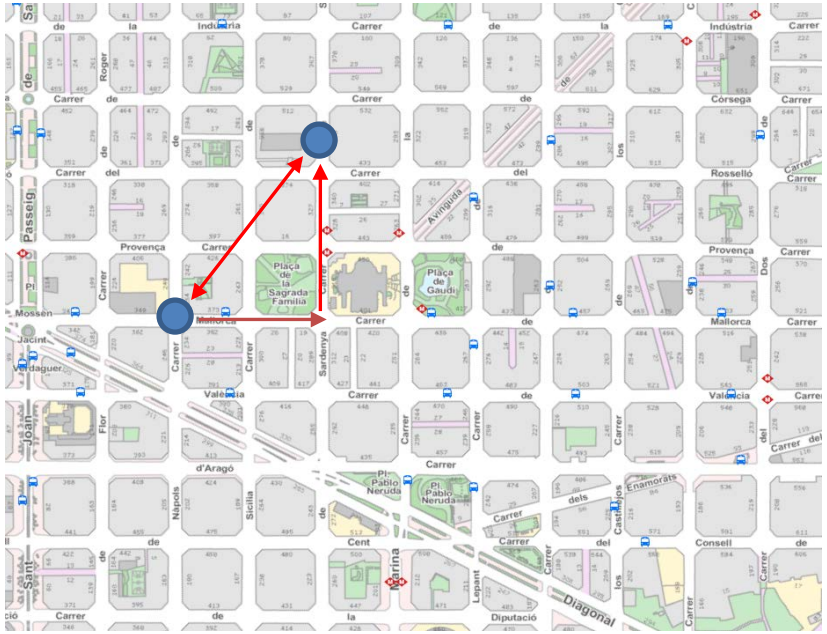

https://w33.bcn.cat/planolBCN/es/guia/zoom/3/angle/44.4/position/431060,4583872/

- **Camino/recorrido**
- **Tiempo empleado**
- **…**

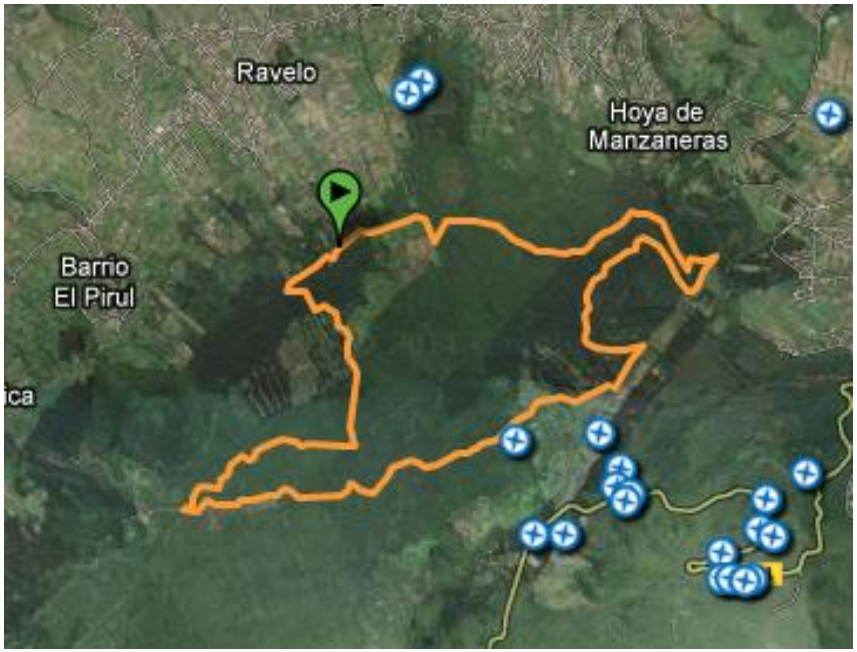

https://www.elsauzal.es/el-municipio/turismo/senderos/1910-2/

Distancia Mahalanobis

$$D^2_{Mah}(x_1, x_2) = (x_{11} - x_{21}, \ldots\ldots, x_{1p} - x_{2p}) \cdot S^{-1} \cdot (x_{11} - x_{21}, \ldots\ldots, x_{1p} - x_{2p})'$$

- **Es invariante frente a transformaciones lineales no singulares de las variables (en particular a cambios de escala)**
- **Se expresa en unidades de desviación típica y tiene en cuenta las correlaciones**
- **La distancia puede incrementar cuando se añade información** $D^2_n \leq D^2_{n+m}$
- $D^2_{n+m} \leq D^2_n + D^2_m$**, la distancia se suma cuando se añaden variables independientes**

Aplicación en multinomiales

Ejemplo 3: frecuencia de observación de especies (inventario)

	Especie 1	Especie 2	Especie 3	Especie 4
Ecosistema 1	0	3	0	2
Ecosistema 2	2	0	1	0
Ecosistema 3	0	20	0	12

Conocimiento experto: la analogía entre los ecosistemas 1 y 3 es superior que entre 1 y 2 o 2 y 3.

¿Porqué?. Los habitats 1 y 3 permiten la presencia de las especies 2 y 4 y son hostiles para las especies 1 y 3. Ocurre lo contrario en el hábitat 2.

Distancia euclidea

dist (E1, E2) = 4.24

dist (E1, E3) = 19.72

dist (E2, E3) = 23.43

LA CARACTERIZACIÓN PROPORCIONADA POR LA DISTANCIA EUCLIDEA NO CONCUERDA CON EL CONOCIMIENTO EXPERTO!!

¿Qué está ocurriendo?

El valor cero tiene un doble significado,

- **Cualitativo: el hábitat es hostil para la especie**
- **Cuantitativo: 0 cómo número**

La distancia euclídea sólo atiende al significado cuantitativo: la distancia entre observar 175 y 185 individuos (muchos en los dos casos) es la misma que la distancia entre observar 0 y 10 (hábitat hostil o hábitat subóptimo)

¿Esto ocurre sólo en inventarios o aplica a otros campos?

Alternativa por perfiles 1/4

Para reducir el efecto cuantitativo resulta razonable estandarizar en porcentaje relativo dentro de cada población (no por variable), cuando esto tiene sentido.

Ejemplo 4: representación gráfica de una matriz de datos bidimensional (4 poblaciones caracterizadas por 2 variables)

	X_1	X_2
P_1	0	10
P_2	2	0
P_3	3	8
P_4	1	4

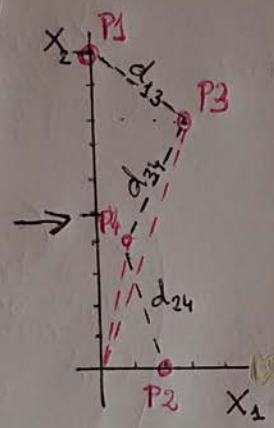

$$d_E(P1,P3) < d_E(P_2,P_4) < d_E(P_3,P_4)$$
$$3{,}61 \qquad 4.12 \qquad 4.47$$

No funciona!

Pero los ángulos si funcionan:

$$\text{ang}(P_3,P_4) < \text{ang}(P_1,P_4) < \text{ang}(P_3,P_1)$$
$$\ldots\ldots < \underbrace{\text{ang}(P_1,P_2)}_{90^\circ \text{ máximo}}$$

Alternativa por perfiles 2/4

Trabajar con ángulos es complicado: vamos a trabajar con medidas pseudo-equivalentes.

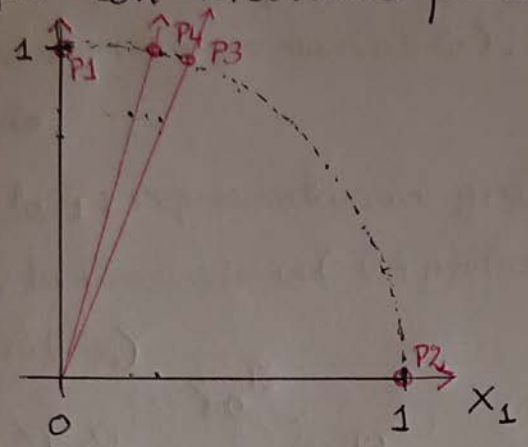

Reducimos el problema a la circunferencia de radio r=1: los ángulos son los mismos.

↓

si el ángulo es mayor, la longitud de la cuerda tambien es mayor

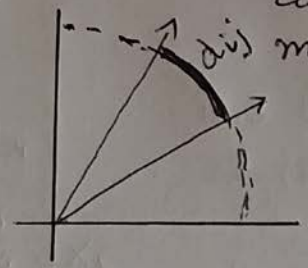

Alternativa por perfiles 3/4

ESTRATEGIA

- **Estandarizar el vector observado (x_{i1}, x_{i2},…, x_{ip}) en cada población**
  - **Frecuencia relativa** $\left(\frac{x_{i1}}{x_{i+}}, \frac{x_{i2}}{x_{i+}}, \ldots, \frac{x_{ip}}{x_{i+}}\right)$, **siendo** $x_{i+} = x_{i1} + \cdots + x_{ip}$ **(dividir por la suma de componentes del vector)**
  - **Vector unitario** $\left(\frac{x_{i1}}{\|x_i\|}, \frac{x_{i2}}{\|x_i\|}, \ldots, \frac{x_{ip}}{\|x_i\|}\right)$, **siendo** $\| x_i \| = (x_{i1} + \cdots + x_{ip})^{1/2}$ **(dividir por la longitud del vector)**
- **Obtener medidas relacionadas con el ángulo entre los vectores (arco, secante, tangente,…): distancia euclídea entre vectores estandarizados o transformados, con o sin ponderación**

Alternativa por perfiles 4/4

VARIANTES

- **Tiene en cuenta el perfil (dirección del vector) pero no la intensidad (longitud): aplica con esfuerzos de muestro son distintos**
  - **Hellinger distance (euclídea transformada)**
  - **Chord distance (euclídea sin transformar)**
  - **Species Profiles distance (euclíeda sin transformar)**
- **Tiene en cuenta el perfil y la intensidad: aplica con igual esfuerzo de muestro: Bray-Curtis distance**

Relación distancia-ángulo 1/3

El producto escalar de vectores

$$x_i \cdot x_j = x_{i1} \cdot x_{j1} + \cdots + x_{ip} x_{jp} = \|x_i\| \, \|x_j\| \cos \theta_{(x_i, x_j)}$$

permite obtener las relaciones angulares. En concreto de

$$\cos \theta_{(x_i, x_j)} = \frac{x_{i1} x_{j1} + \cdots + x_{ip} x_{jp}}{\|x_i\| \, \|x_j\|} = x_{i1} x_{j1} + \cdots + x_{ip} x_{jp}$$

cuando $\|x_i\| = \|x_j\| = 1$, se tiene

$$2 - 2\cos\theta = \underbrace{x_{i1}^2 + \cdots + x_{ip}^2}_{\|x_i\|=1} + \underbrace{x_{j1}^2 + \cdots + x_{jp}^2}_{\|x_j\|=1} \underbrace{- 2x_{i1} x_{j1} \cdots - 2x_{ip} x_{jp}}_{-2\cos\theta}$$

$$= (x_{i1} - x_{j1})^2 + \cdots + (x_{ip} - x_{jp})^2 = \sum_{k=1}^{p} (x_{ik} - x_{jk})^2$$

Así, utilizando las razones trigonométricas del ángulo mitad,

$$\text{dist}(x_i, x_j) = \sqrt{\sum_{k=1}^{p} (x_{ik} - x_{jk})^2} = \sqrt{2(1 - \cos\theta)}$$

$$= \sqrt{4 \operatorname{sen}^2 \frac{\theta}{2}} = 2 \cdot \operatorname{sen} \frac{\theta}{2}$$

Relación distancia-ángulo 2/3

<u>Conclusión.</u>

dist (x_i, x_j) es una función monotona creciente del ángulo θ (más ángulo $\Rightarrow$ más distancia entre los perfiles)

Hellinger distance (ejemplo)

$$(x_{i1}, x_{i2}, \dots x_{ip}) \longrightarrow \left(\frac{x_{i1}}{x_{i+}}, \dots, \frac{x_{ip}}{x_{i+}}\right)$$

convierte a frecuencias relativas

$$\downarrow$$

$$\left(\sqrt{\frac{x_{i1}}{x_{i+}}}, \dots, \sqrt{\frac{x_{ip}}{x_{i+}}}\right)$$

transforma $\sqrt{\ }$ (reduce el peso de los extremos superiores)

$$\downarrow$$

$$d_{Hell}(x_i, x_j) = \sqrt{\sum_{k=1}^{p} \left(\sqrt{\frac{x_{ik}}{x_{i+}}} - \sqrt{\frac{x_{jk}}{x_{j+}}}\right)^2}$$

$$\left\| \left(\sqrt{\frac{x_{i1}}{x_{i+}}}, \dots, \sqrt{\frac{x_{ip}}{x_{i+}}}\right) \right\| = \frac{x_{i1}}{x_{i+}} + \dots + \frac{x_{ip}}{x_{i+}} = 1$$

. Así, dist_{Hell} es una función del ángulo!

Relación distancia-ángulo 3/3

Interpretación geométrica de la medida $2\,\text{sen}\,\frac{\theta}{2}$

$$2\,\text{sen}\,\frac{\theta}{2} = \sqrt{2-2\cos\theta} = \sqrt{1-2\cos\theta+\cos^2\theta+\text{sen}^2\theta}$$

$$= \sqrt{(1-\cos\theta)^2+\text{sen}^2\theta} = \sqrt{x^2+h^2} = c$$ (longitud de la cuerda)

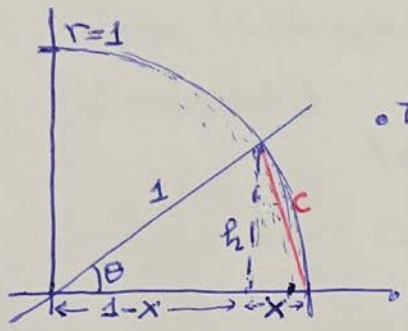

- Triangulo izquierda

$\cos\theta = \frac{1-x}{1} = 1-x \Rightarrow (1-\cos\theta)^2 = x^2$

$\text{sen}\,\theta = \frac{h}{1} = h \Rightarrow \text{sen}^2\theta = h^2$

- Triángulo derecho

$c^2 = x^2+h^2$ (T. Pitágoras)

Conclusión.

$\text{dist}(x_i, x_j)$ es la longitud de la cuerda que separa los vectores unitarios (estandarizados)

Ponderación en distancia χ^2

Tabla de contingencia

	A_1	A_2	.....	A_p	
Pob-i	f_{i1}	f_{i2}	.....	f_{ip}	f_{i+}
Pob-j	f_{j1}	f_{j2}	.....	f_{jp}	f_{j+}
	f_{+1}	f_{+2}		f_{+p}	f_{++}

$$d_{\chi^2}(\text{Pob-i}, \text{Pob-j}) = \sqrt{\sum_{k=1}^{p} \left[\frac{f_{ik}}{(f_{i+} \cdot f_{+k})/f_{++}} - \frac{f_{jk}}{(f_{j+} \cdot f_{+k})/f_{++}} \right]^2}$$

$$= \sqrt{\sum_{k=1}^{p} \left(\frac{f_{++}}{f_{+k}} \right)^2 \cdot \left(\frac{f_{ik}}{f_{i+}} - \frac{f_{jk}}{f_{j+}} \right)^2}$$

$$= \sqrt{\sum_{k=1}^{p} \left(\frac{f_{++}}{f_{+k}} \right)^2 (\hat{p}_{ik} - \hat{p}_{jk})^2}$$

factor de ponderación